INTELIGENTNI MULTIAGENTSKI SUSTAVI

2. MI 2010./2011.

1. **(7 bodova)** Neki kolegij upisalo je troje studenata. Kao uvjet za polaganje kolegija studenti trebaju riješiti zadatak za domaću zadaću, pri čemu smiju i surađivati. Zadatak je takav da ga nijedan od studenata ne može riješiti sam, tj. student koji pokuša samostalno riješiti zadatak ostvariti će 0 bodova. Bilo koja dva studenta zajedničkim radom na zadatku ostvariti će ukupno 4 boda, a suradnjom svih triju studenata bit će ostvareno ukupno m bodova. Studenti potom mogu međusobno raspodijeliti ostvarene bodove kako god žele.
   a. Prikažite problem kao igru u karakterističnom obliku.
   b. Dokažite da je za sve m < 6 jezgra prazna.
   c. Odredite jezgru za m = 6.
   d. Odredite Shapleyjevu vrijednost za svakog igrača za jezgru, pri m = 6.
2. **(6 bodova)** U tablici je prikazana igra u normalnom obliku. Akcije agenta 1 su u retcima, a akcije agenta 2 u stupcima.

	L	R
U	(2, 1)	(3, 1)
D	(4, 0)	(1, 3)

   a. Odredite model protivnika obaju agenata, uz pretpostavku da se učenje obavlja kroz 6 iteracija te da su inicijalne vrijednosti težinske funkcije agenta 1 za akcije (L, R) agenta 2 jednake (2.5, 1), a težinska funkcija agenta 2 za akcije (U, D) iznosi (1, 1).

s_i	s_j	k_i (L)	k_i (R)	k_j (U)	k_j (D)	Pr_i [L]	Pr_i [R]	Pr_j [U]	Pr_j [D]
-	-	2.5	1	1	1	0.71	0.29	0.5	0.5
D	R	2.5	2	1	2	0.56	0.44	0.33	0.67
D	R	2.5	3	1	3	0.45	0.55	0.25	0.75
U	R	2.5	4	2	3	0.38	0.62	0.4	0.6
U	R	2.5	5	3	3	0.33	0.67	0.5	0.5
U	R	2.5	6	4	3	0.29	0.71	0.57	0.43
U	R	2.5	7	5	3	0.26	0.74	0.63	0.37

   b. Pretpostavimo da inicijalne vrijednosti težinskih funkcija agenata nisu precizno poznate, ali je poznato da se nalaze u intervalu [1,10]. Odgovorite koje od četiriju mogućih zajedničkih akcija mogu biti odigrane u milijuntom koraku fiktivne igre. Ukratko obrazložite odgovor.

(Intuitivno se vidi iz a. podzadatka.) Kako je uvijek Pr_j [D] > 0, akcija R će uvijek imati veće očekivanje dobiti od akcije L za agenta 2 te će ju on zato uvijek odabrati, neovisno o vjerojatnostima. Nakon određenog broja koraka (puno manjeg od milijun) Pr_i [L] postat će dovoljno velika kako bi akcija U bila isplativija za agenta 1 neovisno o početnim težinskim funkcijama. Nakon toga će agenti do beskonačnosti ponavljati akcije (U, R) pa će to odigrati i u milijuntom koraku.

3. **(6 bodova)** Razmatramo aksiomatske koncepte rješenja pri problemu pregovaranja. Odgovorite:
    a. Je li moguće da Pareto optimalan dogovor nije utilitarističko rješenje? Ako je odgovor potvrdan, navedite primjer; ako je negativan, obrazložite.
    Ne mora biti utilitarističko rješenje.
    Primjer. Neka su zadane točke: (2, 4) i (4, 3) te neka se razmatra prva točka. Ona je Pareto optimalna, no nije utilitarsitčko rješenje jer je to druga.
    b. Je li moguće da utilitarističko rješenje nije Pareto optimalno? Ako je odgovor potvrdan, navedite primjer; ako je negativan, obrazložite.
    Nije moguće. Utilitarističko je rješenje Pareto optimalno po definiciji jer maksimizira sumu ostvarenih korisnosti. (Ims 8, 9)
    c. Je li moguće da ravnopravno rješenje društvene dobrobiti nije Pareto optimalno? Ako je odgovor potvrdan, navedite primjer; ako je negativan, obrazložite.
    Nije moguće jer je ravnopravno rješenje društvene koristi po definiciji Pareto optimalno. (Ims 8, 7)
4. **(6 bodova)** Problem višeagentske alokacije zadataka prikazan je tablicom.

δ	$s_1(\delta)$	$s_j(\delta)$	$c_1(\delta)$	$c_j(\delta)$	$U_1(\delta) = 8 - c_1(\delta)$	$U_j(\delta) = 8 - c_j(\delta)$
δ^1	0	$\{t_1, t_2, t_3\}$	0	8	8	0
δ^2	$\{t_1\}$	$\{t_2, t_3\}$	1	4	7	4
δ^3	$\{t_2\}$	$\{t_1, t_3\}$	2	5	6	3
δ^4	$\{t_3\}$	$\{t_2, t_3\}$	4	7	4	1
δ^5	$\{t_2, t_3\}$	$\{t_1\}$	6	4	2	4
δ^6	$\{t_1, t_3\}$	$\{t_2\}$	5	3	3	5
δ^7	$\{t_1, t_2\}$	$\{t_3\}$	3	1	5	7
δ^8	$\{t_1, t_2, t_3\}$	0	7	0	1	8

a. Grafički vizualizirajte problem, uz pretpostavku da je moguća zamjena samo jednog zadatka u koraku.

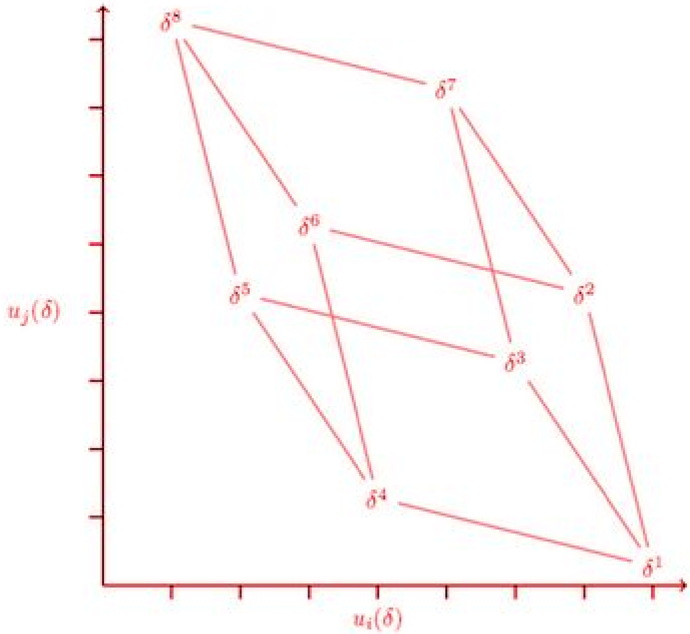

b. Krene li se od početnog dogovora δ^1, koji će dogovor dostići pohlepni algoritam u osnovnom slučaju, a koji ako se uvede mogućnost kompenzacije novčanim plaćanjem? Obrazložite.
U osnovnom slučaju algoritam se neće maknuti iz početnog stanja jer niti jedna zamjena neće odgovarati agentu budući da će značiti gubitak korisnosti za njega.
Ako se uvede mogućnost plaćanja, dostići će se utilitarističko rješenje δ^7 nizom δ^1 ➡ δ^2 ➡ δ^7.

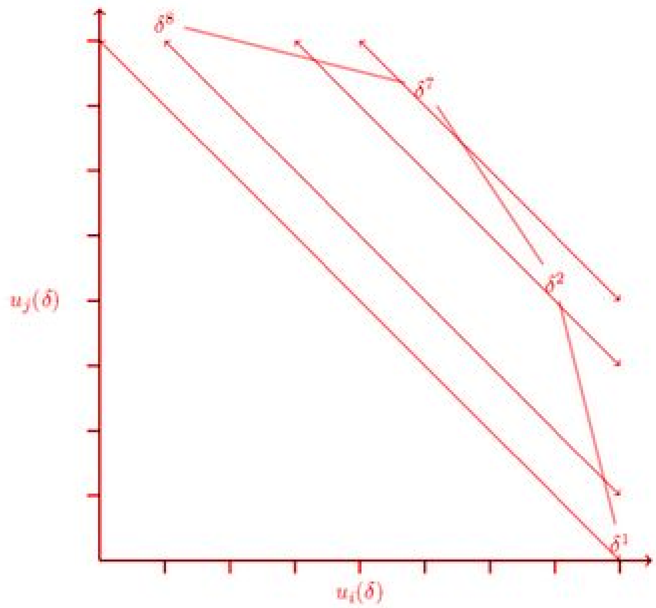

ZI 2010./2011.

1. **(8 bodova)** U kombinatoričkoj aukciji prodaje se pet figurica: Beast Boy, Robin, Raven, Starfire i Cyborg. Zaprimljene ponude dane su u tablici dolje:

Price	Bid item
$1	Beast boy
$3	Robin
$5	Raven, Starfire
$4	Cyborg, Robin
$6	Cyborg, Beast Boy
$3	Raven, Beast Boy

   a. konstruirajte stablo po predmetima
   b. odredite za ponuđača najbolji skup ponuda
   c. Odredite ubrzanje koje se postiže uz usporedbu grananja po predmetima, ako je poznato da centralizirani algoritam pretraživanja cjelokupnog prostora stanja za 5 predmeta zahtijeva pretraživanje 52 stanja.
   (Prema algoritmu iz službenog podsjetnika)

1. a)

Bb	~~8~~ 1	1
Ro	~~8~~ 3	4
Ra, St	~~8~~ 5	3, 5
Cy, Ro	~~8~~ 4	2, 4
Cy, Bb	~~8~~ 6	1, 2
Ra, Bb	~~8~~ 3	1, 3

Bb - 1, Cy - 2, Ra - 3, Ro - 4, St - 5

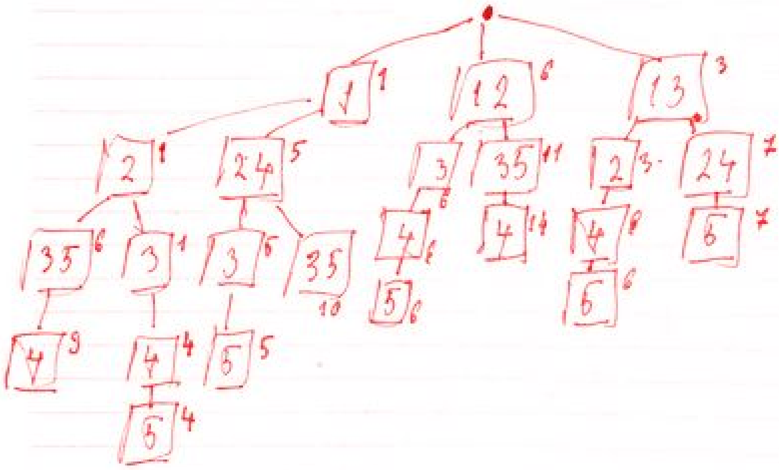

b) 12, 35, 4 → 6 + 5 + 3 = 14

c) Stablo ima 8 puteva.

$\frac{52}{8} = 6,5$

2. (6 bodova)

a. Ukratko objasnite osnovnu ideju Groves-Clarksovog mehanizma.
Plaća agenta proporcionalna je vrijednostima ostalih agenata. Što znači da agent istinom poboljšava društvenu dobrobit.

b. Objasnite Groves-Clarksov mehanizam na primjeru 5 agenata (Alice, Bob, Caroline, Donald, Emiliy) koji bojaju kuću *trokatnicu*. Svi agenti od bojanja kuće ostvaruju subjektivnu korist 10, osim Boba kojem baš nije do bojanja, pa ostvaruje korist 0. Bojanje košta 20 jedinica, a trošak se dijeli na agente koji glasaju za bojanje. Pokažite da se agentu kod korištenja ovog mehanizma ne isplati lagati o svojim preferencijama.

Name	$v_i(o,\tilde{\theta})$	$v_i(o,\theta)+\sum_{j\neq i} v_j(\tilde{\theta})$
Alice	$10-\frac{20}{4}=5$	$5+15=20$
Bob	$0-0=0$	$0+20=20$
Caroline	$10-\frac{20}{4}=5$	$5+15=20$
Donald	$10-\frac{20}{4}=5$	$5+15=20$
Emily	$10-\frac{20}{4}=5$	$5+15=20$

Ako nitko ne laže, plaća je svima jednaka i iznosi 20.

Name	$v_i(o,\tilde{\theta})$	$v_i(o,\theta)+\sum_{j\neq i} v_j(\tilde{\theta})$
Alice	$0-0=0$	$10+(\frac{10}{3}\cdot 3)=20$
Bob	$0-0=0$	$0+(\frac{10}{3}\cdot 3)=10$
Caroline	$10-\frac{20}{3}=\frac{10}{3}$	$\frac{10}{3}+(\frac{10}{3}\cdot 2)=10$
Donald	$10-\frac{20}{3}=\frac{10}{3}$	$\frac{10}{3}+(\frac{10}{3}\cdot 2)=10$
Emily	$10-\frac{20}{3}=\frac{10}{3}$	$\frac{10}{3}+(\frac{10}{3}\cdot 2)=10$

Ako Alice laže, plaća joj je opet 20, a drugima pada na 10. Vidimo da Alice time ništa ne dobiva. Laganje joj se čak možda i ne isplati jer je vjerojatnost da će se kuća obojati manja budući da je ukupna plaća ostalih agenata u prvom slučaju 80, a u drugom 40.

3. **(7 bodova)** Potrebno je strukturom TAEMS prikazati hijerarhiju ciljeva za agenta MountNešto. Agent modelira proizvođača planinarske opreme koji proizvodi vreće za spavanje i ruksake za planinarenje. Cilj „Proizvedi“ je glavni cilj agenta, koji odgovara proizvođenju jednog komada gorske opreme (ruksak ili vreća). Izrada ruksaka razlaže se na sljedeće korake:
    a. izrada zatvarača (koristi resurs „materijal za zatvarače“)
    b. izrezivanje tkanine (koristi resurs „materijal za tkaninu“)
    c. šivanje finalnog proizvoda (Posljednji korak šivanje moguće je obaviti tek nakon što su prethodna 3 završena.)

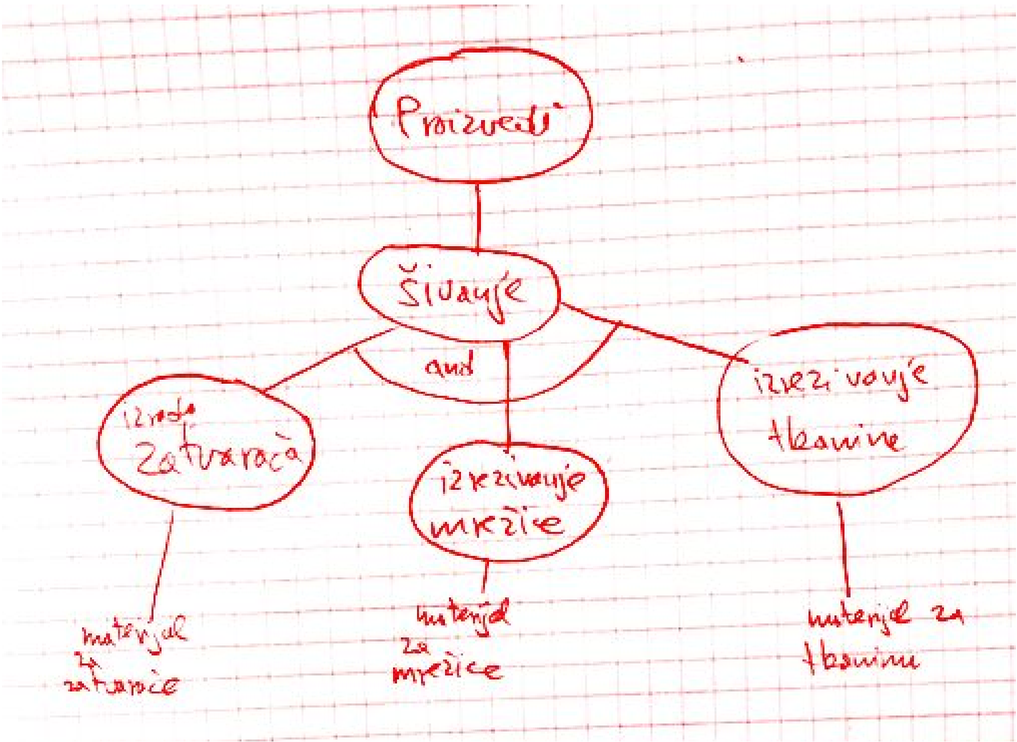

4. **(7 bodova)** Ukratko objasnite osnovnu ideju optimizacije algoritmom kolonije mrava.
   (Nema u prezentacijama.)
5. **(7 bodova)** Navedite i ukratko opišite procedure (funkcije) algoritma asinkronog vraćanja te za svaku objasnite u kojim se situacijama ona poziva i izvodi.
   (Piše na službenom podsjetniku.)

2. MI 2012./2013.

1. **(7 bodova)** U nekom sustavu nalaze se tri agenta. Svaki agent *i* može odabrati dvije moguće akcije: $a_i = 1$ i $a'_i = 0$. Isplata tima za zajedničku akciju $a = (a_1, a_2, a_3)$ može se izraziti linearnom kombinacijom triju lokalnih funkcija isplate, kao: $u(a) = f_{12}(a_1, a_2) + f_{13}(a_1, a_3) + f_{23}(a_2, a_3)$, gdje je $f_{ij}(a_i, a_j) = 2a'_i a_j + 3a_i a'_j$
   a. Prikažite koordinacijski graf koji opisuje ovaj problem
   b. Odredite optimalnu zajedničku akciju triju agenata u ovakvom sustavu
2. **(6 bodova)** Neki sustav početno se sastoji od 100 agenata koji koriste postupak učenja u skladu s dinamikom replikatora. Agenti su identični i na raspolaganju su im tri moguće akcije: *a*, *b* i *c*. Agenti su nasumično upareni, a strateška igra koja opisuje zajedničko odlučivanje svakog para prikazana je tablicom dolje. Početno, akciju *a* odabire 40 agenata, a akcije *b* i *c* po 30. Odredite koliki broj agenata odabire

pojedine akcije nakon 1., 2. i 3. koraka učenja.

		j		
		a	*b*	*c*
	a	1,1	2,2	0,0
i	*b*	0,0	1,1	2,2
	c	2,2	0,0	1,1

Dinamika replikatora

Udio agenata:

$$\theta^t(s) = \frac{\phi^t(s)}{\sum_{s' \in S} \phi^t(s')}$$

Očekivana korisnost:

$$u^t(s) \equiv \sum_{s' \in S} \theta^t(s') u(s, s'),$$

Stopa razmnožavanja:

$$\phi^{t+1}(s) = \phi^t(s)(1 + u^t(s)).$$

3. **(6 bodova)** Razmatramo aksiomatske koncepte rješenja pri problemu pregovaranja. Odredite:
    a. Je li moguće da Pareto optimalan dogovor nije utilitarističko rješenje? Ako je odgovor potvrdan, navedite primjer; ako je negativan, obrazložite
    b. Je li moguće da utilitarističko rješenje nije Pareto optimalno? Ako je odgovor potvrdan, navedite primjer; ako je negativan, obrazložite.
    c. Je li moguće da ravnopravno rješenje društvene dobrobiti nije Pareto optimalno? Ako je odgovor potvrdan, navedite primjer; ako je negativan, obrazložite.
    (odgovoreno u 2. MI 2010./2011.)
4. **(6 bodova)** Razmatramo upotrebu algoritma simuliranog kaljenja za pronalaženje optimuma složenih dogovora pri pregovaranju. Odgovorite:
    a. Koja je prednost ovog algoritma pred pohlepnim “hill-climbing” algoritmom? Jamči li simulirano kaljenje da će biti pronađen globalni optimum?
    Neće konvergirati k prvom lokalnom optimumu kao što bi pohlepni algoritam to učinio. Ne jamči da će biti pronađen globalni optimum, iako ga u praksi često pronalazi.
    b. Koja se tri tipa agenta koriste u ovom algoritmu? Ukratko opišite funkcionalnost svakog od njih.
    Posrednik (mediator) - predlaže dogovore ostalim agentima, ako oba agenta prihvate ponudu, mutira ju te ju ponovo predlaže agentima; ako jedan ili više agenata odbije ponudu, mutira se zadnja prihvaćena
    Penjač (Hill Climber) - prihvaća ponudu samo ako je korisnost veća od korisnosti ne prihvaćanja nikakvog dogovora (početna korisnost) i veća od korisnosti zadnje prihvaćene ponude

Kalitelj (Annealer) - prihvaća ponudu ako je bolja od zadnje kao i “penjač”, ali također može prihvatiti i lošiju ponudu s vjerojatnošću $max\,(1,\ e^{\frac{-\Delta U}{T}})$ pri čemu je *ΔU* razlika korisnosti među ponudama, a *T* temperatura koja opada s vremenom

ZI 2012./2013.

1. **(7 bodova)** Slika dolje prikazuje transportnu mrežu. Svaki od šest agenata (A do F) vlasnik je jedne usmjerene veze između čvorova. Veze se koriste kako bi se ostvarila veza od čvora S do cvora T. Vrijednost koju agent ostvaruje od korištenja njegove veze naznačena je na slici i označena je s v_i (ove vrijednosti su negativne, što označava cinjenicu da korištenje veze za agenta predstavlja trošak). Agent ostvaruje vrijednost 0 ako se njegova veza ne koristi. Odredite koji će od četiri moguća puta od čvora S do čvora T biti korišten ako se za isplatu agenata upotrijebi Groves-Clarkeov mehanizam. (Iz rješenja mora biti vidljiv postupak!)

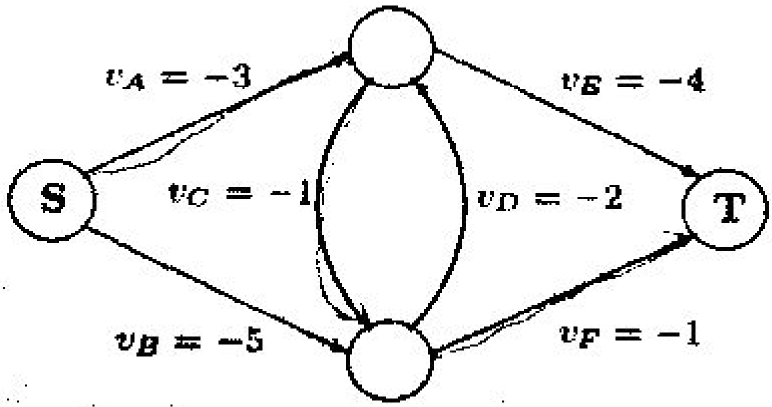

2. **(8 bodova)** U kombinatoričkoj aukciji prodaju se četiri predmeta: A, B, C i D. Zaprimljene ponude prikazane su u tablici dolje.

Cijena	Skup predmeta
2	A
1	C
4	A, B
3	B, C
4	A, C, D
6	B, C, D

   a. Konstruirajte stablo grananja po **ponudama** (krenite od čvora **A** kao korijena, a daljnje čvorove dodajte redom kao u tablici; *za nepoštivanje ovog redoslijeda gubiti će se bodovi*).
   b. Na temelju izgrađenog stabla odredite najpovoljniji skup ponuda za prodavatelja.

(Prema algoritmu iz službenog šalabahtera.)

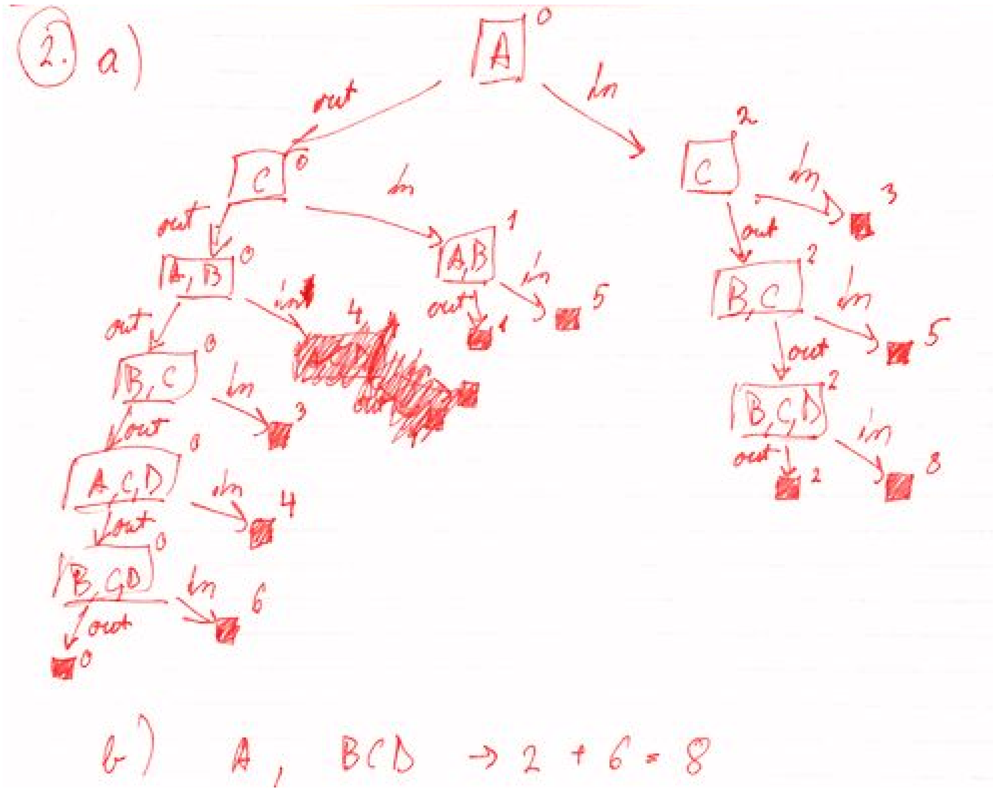

c. Koja je prednost korištenja grananja po ponudama u odnosu na grananje po predmetima?

U praksi, grananje po ponudama je često brže od grananja po predmetima jer nam daje veću kontrolu nad poretkom ponuda pa možemo bolje optimizirati poredak ponuda. Također, grananje po ponudama ne zahtijeva dodavanje lažnih pojedinačnih ponuda.

d. Općenito, zašto se koristi stablo grananja po ponudama (ili predmetima) umjesto izravnog pretraživanja cjelokupnog prostora stanja?

Zato jer je ukupan broj mogućih skupova ponuda jako velik (ravna se prema Stirlingovoj formuli), a korištenjem stabala razmatraju se samo ostvarivi skupovi ponuda, čiji je broj puno manji te je algoritam time znatno brži.

3. **(6 bodova)** Ukratko opišite četiri glavne vrste glasovanja (većinsko, u dva kruga, po parovima, Bordin zbroj). Za svaku vrstu navedite zadovoljava li reflektirajuću, te zadovoljava li rotirajuću simetriju.

Većinsko glasovanje: zbroje se svi glasovi, pobjednik je onaj koji ima najviše glasova. Ne zadovoljava reflektirajuću simetriju.

Glasovanje u dva kruga: u drugi krug glasovanja ulaze dva najbolja iz prvog kruga; prvi i drugi krug se odvijaju po mehanizmu većinskog glasovanja. Ne zadovoljava reflektirajuću simetriju.

Glasovanje po parovima: glasovanje nad svim parovima kandidata (onoliko glasovanja koliko ima parova kandidata); pobjednik je onaj kandidat koji ima najviše nezavisnih pobjeda (npr. neka je par (pivo, vino) ➡ 6 osoba za vino (drugi izbor), 5 osoba za pivo i 4 osobe za vino ➡ pobjednik je vino). Ne zadovoljava rotirajuću simetriju.

Bordov zbroj: Ako postoji X mogućih izbora, tada svaki agent dodjeljuje X bodova svom prvom izboru, X-1 bodova svom drugom izboru itd.; pobjeđuje kandidat s najvećim brojem bodova. Zadovoljava obje simetrije.
Reflektirajuća simetrija: ako jedan agent preferira odabir A nad B, a drugi agent preferira B nad A, tada se njihovi glasovi međusobno isključuju
Rotirajuća simetrija: ako su preferencije jednog agenta (A, B, C), drugog agenta (B, C, A), a trećeg (C, A, B), tada se njihovi glasovi međusobno isključuju.

4. **(7 bodova)** Za igru u karakterističnom obliku prikazanu sljedećom tablicom:

S	$v(S)$
()	0
(1)	1
(2)	3
(12)	6

   a. Nabrojite sve moguće *koalicijske strukture*.
      {{1},{2}}, {{1,2}}
   b. Odredite *jezgru*.
      - općenito, rješenje $\vec{u}$ je **stabilno** ako je ostvarivo te ako nijedan podskup agenata ne može postići veću isplatu od isplate koju dobiva u $\vec{u}$.

      - **Jezgra** = skup svih stabilnih rješenja

      {1,5}, {2,4}, {3,3}
   c. Odredite *Shapleyevu vrijednost za koaliciju* (12).

$$\phi(i, A) = \sum_{S \subseteq A} \frac{(|A| - |S|)!\,(|S| - 1)!}{|A|!}[v(S) - v(S - \{i\})]$$

      fi(1, {1,2}) = 2
      fi(2, {1,2}) = 4

5. **(7 bodova)** Za što se koriste TAEMS strukture u višeagentskim sustavima? Nacrtajte primjer TAEMS strukture sa svim karakterističnim elementima. Označite koji dio slike predstavlja koji karakteristični element i ukratko opišite svaki od tih elemenata.

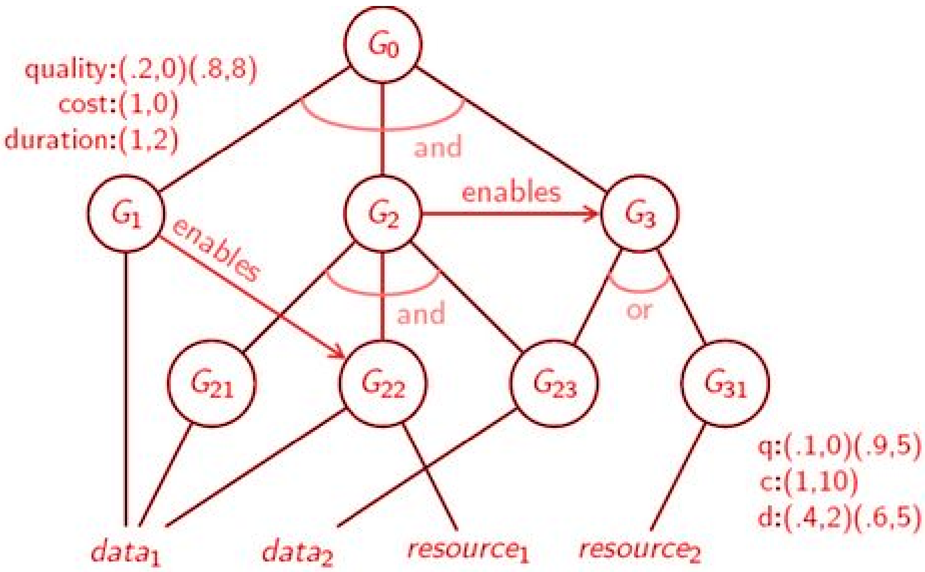

TAEMS struktura koristi se za prikaz hijerarhija ciljeva, planova i politika. Dodatno, to je zapravo jezik za prikaz velikih hijerarhija zadataka koje sadrže kompleksna ograničenja među zadatcima (ims 12,3).

Korijen stabla - cilj najviše razine. Djeca su podciljevi koje je potrebno izvršiti da bi se ostvarili ciljevi više razine. Djeca mogu biti spojeni operatorima *and, or* ili drugima koji označavaju ovisnosti između podciljeva i ciljeva. Listovi su ili *ciljevi* koje može *ostvariti* pojedinačni agent ili *zadaci* koje može *obaviti* agent.
Ciljevi i zadaci mogu zahtjevati korištenje resursa (ograničeni su) ili podataka (neograničeni su). Oni su prikazani na dnu grafa.
Strelica *enables* označava nelokalne efekte - obavljanje jednog zadatka omogućuje obavljanje drugog.
Zadaci mogu biti parametrizirani trima parametrima - kvaliteta, trošak i trajanje. (ims 12, 4-7)

ZI 2013./2014.

1. ZI 2012./2013., 1. zadatak.
2. Sličan kao ZI 2012./2013., 2. zadatak. Nova tablica je:

Predmeti	**Cijena**
{1}	6
{2}	3
{3,4}	12
{1,3}	12
{2,4}	8
{1,3,4}	16

a. izgradi stablo **po predmetima**!
b. iz stabla odredi najpovoljniji skup ponuda
(Sličan kao i 1. Zadatak iz ZI 2010./2011.)

3. Dva agenta (1 i 2) pregovaraju o predmetima x i y. Vrijedi $x + y = 5$, $x \geq 0$, $y \geq 0$. Funkcije korisnosti agenata su:

   $u_1 (x, y) = 2x + y$
   $u_2 (x, y) = x + 3y$

   Primjeni protokol monotonih ustupaka (za fiksan iznos ustupaka, 1). Prikaži postupak tablično. Odredi koji je konačan dogovor agenata. NAPUTAK: svedi problem na problem s jednim predmetom.

   $u_1 (x, y) = 2x + y = x + 5$
   $u_2 (x, y) = x + 3y = 15 - 2x$
   $u_1^* (5, 0) = 10$
   $u_2^* (0, 5) = 15$

x_1	y_1	u_1 (1)	u_1 (2)	x_2	y_2	u_2 (2)	u_2 (1)
5	0	10	-	0	5	15	5
4.5	0.5	9.5	5	0.5	4.5	14	6
4	1	9	5.5	1	4	13	7
3.5	1.5	8.5	6	1.5	3.5	12	8
3	2	8	6.5	2	3	11	9
2.5	2.5	7.5	7	**2.5**	**2.5**	**10**	**10**

   Konačan dogovor je (x, y) = (2.5, 2.5). $u_1 = 7.5$, $u_2 = 10$.

4. ZI 2012./2013., 5. zadatak - TAEMS.
5. Nansova metoda. Kao Bordinova metoda, ali obavlja se u više krugova. U svakom krugu izbacuje se kandidat s najmanjim zbrojem. Zadnji koji ostane je pobjednik. Trebalo je odrediti pobjednika tom metodom za sljedeću situaciju:

   3 agenta - a > b > c
   2 agenta - a > c > b
   4 agenta - b > c > a

ZI 2014./2015.

1. ZI 2013./2014., 3. zadatak (protokol monotonih ustupaka)
2. Grananje po ponudama (drugačije je zadano nego prijašnjih godina, imaš tri agenta i popis ponuda po agentima, te se neke ponude ponavljaju)
3. Teorija (TAEMS, isto pitanje kao zadnje dvije godine)

4. Za većinsko glasovanje i Bordov broj odredi da li vrijedi **ime** pravilo (on ga zada i opiše). Pravilo je to da ako je neka ponuda pobjednik u glasovanju da onda mora biti pobjednik i u glasovanju u paru. Provjeri je li to doista ispunjeno za gore navedena.

   Kod glasovanja svaki agent ima poreda moguće izbore po svom prioritetu. Agent odabire najviši izbor koji je još u igri

   1. Ako postoji **X** mogućih izbora, tada svaki agent dodjeljuje **X** bodova svom prvom izboru, **X-1** bodova svom drugom izboru,...
   2. Pobjeđuje kandidat sa najvećim brojem bodova

   Na slici je opisan Bordov broj.

   Većinsko glasovanje - zbroje se svi glasovi, pobijeđuje onaj s najviše glasova

   Glasovanje u dva kruga - u drugi krug ulaze dva najbolja iz prvog kruga te se ponovno glasuje.

   Glasovanje po parovima - pobjednik je onaj koji ima najviše nezavisnih pobjeda. Uparuju se svi izbori (*n* povrh 2 načina, *n* je broj izbora) i pobjedniku se dodaje bod.

5. Teorija (opisati što je mehanizam, postupak Groves-Clarke mehanizma i Vickery-Clarke-Groves, razlike između njih)

   Postoji želja za glasovanjem agenata oko zajedničkog predmeta raspravljanja. Mehanizmi su načini evaluiranja rezultata glasovanja. Postoje različiti mehanizmi glasovanja koji vode do različitih rješenja.

   Groves-Clarke (ims 11,23).

   Plaća agenta proporcionalna je vrijednostima ostalih agenata. Što znači da agent istinom poboljšava društvenu dobrobit.

   Vickery-Clarke-Groves (ims 11,32)

   Mjeri se doprinos agenta cjelini

   - Korisnost "divnog života"
   - U praksi nije lagan izračun
   - Bolja ravnoteža prihoda